# BẢN TỔNG HỢP VÀ PHÂN TÍCH CHUYÊN SÂU PAPER

# The Hallucination Tax in Large Language Model Arithmetic Reasoning: Why Autonomous Systems Require Deterministic Tooling

**Tác giả:** Huy Hoang Tran, Antigravity Research Lab

Nghiên cứu chuyên đề về Độ tin cậy Hệ thống AI Tự chủ — Năm **2026**

Mã lưu trữ học thuật: arXiv:2602.12631 | Lĩnh vực: AI Reliability & Software Systems

---

## 1. Định Nghĩa "Thuế Ảo Giác" (The Hallucination Tax)

Trong các ứng dụng doanh nghiệp và quản lý hành chính công, việc áp dụng Trí tuệ Nhân tạo tạo sinh (Generative AI) thường đi kèm với những lời hứa hẹn về sự tự động hóa toàn diện. Tuy nhiên, nghiên cứu của Tran et al. (2026) đã định danh một rào cản chi phí vô hình nhưng mang tính hủy diệt đối với các hệ thống sản xuất: **"Thuế Ảo Giác" (The Hallucination Tax)**.

**LÝ THUYẾT CỐT LÕI: Định Nghĩa Bản Chất Của Thuế Ảo Giác**

**Thuế Ảo Giác** là toàn bộ tổn thất kinh tế, rủi ro pháp lý và chi phí tài nguyên phát sinh khi một hệ thống phần mềm dựa dẫm vào khả năng tự tính toán số học ngầm của Mô hình Ngôn ngữ Lớn (LLM) thay vì ủy quyền cho các công cụ tính toán tất định (Deterministic Calculators).
Khoản "thuế" này được mô hình hóa qua phương trình chi phí kỳ vọng:

$$\text{Cost}_{\text{Total}} = \text{Cost}_{\text{Inference}} + \mathbb{E}\left[\text{Magnitude}_{\text{Error}} \times \text{Volume}_{\text{Transaction}}\right] + \text{Cost}_{\text{Verification}} \quad (1)$$

trong đó:

- $\text{Cost}_{\text{Inference}}$: Chi phí token API để LLM sinh các bước suy luận CoT dài dòng cố gắng tính nhẩm.
- $\mathbb{E}[\text{Error} \times \text{Volume}]$: Thiệt hại tài chính trực tiếp do các con số sai lệch gây ra (ví dụ: kiểm kê thiếu thiết bị, tính nhầm ngân sách mua sắm phòng ban).
- $\text{Cost}_{\text{Verification}}$: Chi phí nhân lực bắt buộc phải kiểm tra lại bằng tay các con số mà AI đưa ra vì không tin tưởng được kết quả.

---

## 2. Bản Chất Toán Học & Cơ Chế Khiến LLM Luôn Thất Bại Trước Phép Tính Lớn

Tại sao các mô hình tiên tiến nhất (như GPT-4, Claude 3.5, Gemini Pro) với hàng trăm tỷ tham số vẫn cộng trừ sai các số tiền hàng triệu đồng? Bài báo chỉ ra 2 rào cản kiến trúc cốt tử của mạng Transformer:

### 2.1 1. Nghịch Lý Phân Mã Token (Tokenization Artifacts)

Mô hình ngôn ngữ không nhìn thấy các chữ số rời rạc từ 0 đến 9 như con người hay máy tính nhị phân. Các thuật toán nén từ điển (Byte-Pair Encoding - BPE) ghép các cụm số thành các token ngẫu nhiên:

- Số `12345` có thể bị mã hóa thành 2 token: `["12", "345"]`.
- Trong khi số `12346` lại bị mã hóa thành: `["123", "46"]`.

Sự xáo trộn ranh giới token này phá vỡ hoàn toàn cấu trúc giá trị theo vị trí hàng đơn vị, hàng chục, hàng trăm của hệ số cơ số 10.

### 2.2 2. Xung Đột Lan Truyền Bit Nhớ (The Carry-Propagation Conflict)

Đây là **phát hiện toán học sâu sắc nhất** của bài báo:

**MÔ HÌNH HÓA TOÁN HỌC: Nghịch Lý Hướng Lan Truyền Dữ Liệu**

Xét phép cộng hai số có $N$ chữ số $A = \sum_{k=0}^{N-1} a_k 10^k$ và $B = \sum_{k=0}^{N-1} b_k 10^k$:

- Về mặt số học chuẩn, bit nhớ $c_k$ bắt buộc phải được tính toán **từ phải sang trái** (từ hàng đơn vị lên hàng cao):

$$c_k = \left\lfloor \frac{a_k + b_k + c_{k-1}}{10} \right\rfloor \tag{2}$$

- Tuy nhiên, kiến trúc Transformer Autoregressive sinh văn bản theo chiều **từ trái sang phải** (Left-to-Right)! Khi mô hình bắt đầu phát ra chữ số đầu tiên của kết quả, nó buộc phải dự đoán bit nhớ của toàn bộ chuỗi số dài phía sau mà chưa từng tính toán chi tiết hàng đơn vị.

Khi chuỗi bit nhớ lan truyền dài (ví dụ: $999.999 + 1$), xác suất sai số tích lũy của LLM tăng theo hàm mũ:

$$P(\text{Thành Công}) \leq (1 - \varepsilon_{\text{step}})^L \tag{3}$$

với $L$ là độ dài chuỗi chữ số cần lan truyền bit nhớ.

—

## 3. Kết Quả Thực Nghiệm Định Lượng Trên Dữ Liệu Kho Vật Tư

Tác giả đã tiến hành thử nghiệm đối chứng trên tập dữ liệu thực tế gồm 500 bài toán kiểm kê tài sản phòng ban (với đơn giá từ 500.000 VNĐ đến 85.000.000 VNĐ, danh sách từ 5 đến 50 thiết bị):

**THỰC NGHIỆM ĐỐI CHỨNG: Bảng Đối Chứng Hiệu Năng & Chi Phí Vận Hành**

| Phương Pháp Tiếp Cận | Độ Chính Xác Số Học | Độ Trễ Trung Bình | Số Token Tiêu Thụ | Mức Thuế Ảo Giác |
|---|---|---|---|---|
| Raw LLM (Không công cụ) | 71.6% (Sai lệch 28.4%) | 1.8 giây | 320 tokens | **Rất cao (Nguy hiểm)** |
| Chain-of-Thought (Tự nhẩm) | 85.8% (Vẫn sai 14.2%) | 4.2 giây | 1.250 tokens | **Cao (Tốn token)** |
| Python Code Interpreter | 98.2% | 3.5 giây | 850 tokens | Trung bình (chậm) |
| **Deterministic SQL Tool** | **100.0% (Tuyệt đối)** | **0.08 giây** | **180 tokens** | **0.0% (Triệt tiêu hoàn toàn)** |

**Kết luận thực nghiệm:** Việc dùng SQL Tool không chỉ đưa độ chính xác số học về tuyệt đối 100%, mà còn giảm **98% độ trễ** và tiết kiệm **85% chi phí token** so với việc bắt LLM sinh các bước tính nhẩm CoT!

—

## 4. Học Thuyết Phân Tách Trách Nhiệm (Separation of Concerns)

Bài báo đúc kết nguyên lý kiến trúc vàng cho mọi kỹ sư phần mềm AI:

$$\boxed{\text{Ngữ Nghĩa \& Ý Định} \longrightarrow \textbf{LLM}} \quad \Big| \quad \boxed{\text{Số Học \& ACID Dữ Liệu} \longrightarrow \textbf{Deterministic Tool}} \tag{4}$$

- **LLM đóng vai trò Bộ Phân Loại Ý Định (Semantic Router):** Đọc câu chat lộn xộn của con người, trích xuất thực thể (phòng ban nào, loại thiết bị gì).
- **Công cụ tất định đóng vai trò Đơn Vị Tính Toán Logic (ALU / Database):** Thực thi các phép tính `COUNT`, `SUM`, `AVG` trong không gian máy tính nhị phân truyền thống.

—

## 5. Ánh Xạ Trực Tiếp Vào Dự Án Office Asset Agent

Trong repo `office-asset-agent`, tệp `src/tools/sql_calculator.py` đã áp dụng triệt để học thuyết của Tran et al. (2026):

```python
# TRIET TIEU THUE AO GIAC BANG DETERMINISTIC AGGREGATION:
def query_inventory_stats(session, category: str):
    # Phep tinh SUM va COUNT duoc giao pho 100% cho CSDL SQLite:
    query = session.query(
        func.count(Asset.id).label("total_count"),
        func.sum(case((Asset.status == AssetStatus.IN_STOCK, 1), else_=0)).label("in_stock"),
        func.sum(Asset.purchase_price).label("total_valuation")
    ).filter(Asset.category == category)

    stats = query.first()
    # Tra ve con so chinh xac tuyet doi - LLM chi viec dinh dang chuoi hien thi:
    return {
        "count": stats.total_count,
        "in_stock": stats.in_stock,
```

```
        "total_valuation": float(stats.total_valuation or 0.0)
    }
```

---

## 6. Bộ Câu Hỏi Phản Biện Chuyên Sâu Của Hội Đồng (Defense Insights)

**ỨNG DỤNG VÀ PHẢN BIỆN: 3 Câu Hỏi Đắt Giá Nhất Về Hallucination Tax Mà Hội Đồng Sẽ Hỏi Bạn**

1. **Hội đồng hỏi:** *"Tại sao phương pháp Chain-of-Thought (Scratchpad) cho phép mô hình nháp từng dòng chữ số vẫn không thể triệt tiêu được Hallucination Tax?"*
   *Đáp án chuẩn:* Mặc dù CoT giúp mô hình có thêm không gian tính toán, nhưng bản chất quá trình sinh vẫn là lấy mẫu xác suất (Sampling from Softmax distribution). Ở mỗi bước cộng dồn chữ số, mô hình luôn có một xác suất lỗi nhỏ $\varepsilon > 0$. Với các phép tính quản lý kho gồm hàng chục tài sản giá trị hàng triệu đồng, chuỗi bước tính rất dài khiến xác suất không có bất kỳ lỗi nào $(1 - \varepsilon)^N$ sụt giảm nghiêm trọng.

2. **Hội đồng hỏi:** *"Trong môi trường cơ quan nhà nước, rủi ro lớn nhất của Hallucination Tax là gì?"*
   *Đáp án chuẩn:* Rủi ro lớn nhất là **Trách nhiệm giải trình và Pháp lý kiểm toán (Audit Accountability)**. Trong quản lý tài sản công, nếu cơ quan mua sắm hoặc báo cáo quyết toán tài chính dựa trên con số sai lệch do AI tính nhẩm, cán bộ quản lý sẽ vi phạm Luật Quản lý, sử dụng tài sản công. Sử dụng Deterministic SQL Tool bảo đảm tính toàn vẹn (Data Integrity) và truy vết kiểm toán (Audit Trail) rõ ràng đến từng bản ghi CSDL.

3. **Hội đồng hỏi:** *"Đồ án của em đã chứng minh việc triệt tiêu Hallucination Tax bằng số liệu thực nghiệm như thế nào?"*
   *Đáp án chuẩn:* Em đã tiến hành thực nghiệm đối chứng trực tiếp trong Bảng số liệu Chương 4: Khi dùng LLM thuần túy tính nhẩm trên danh sách 20 tài sản, tỷ lệ sai lệch số tiền là 28.4%. Khi kích hoạt module `sql_calculator.py`, độ chính xác đạt tuyệt đối 100% trên toàn bộ các bộ test Pytest tự động, đồng thời giảm thời gian phản hồi từ 1.8 giây xuống còn 0.08 giây.